


Détection des véhicules éloignés, de petite taille et dans les embouteillages

Scène de trafic urbain appliquée au contexte béninois :
proposition d'amélioration basée sur YOLOv8



AVANT 4 véhicules détectés



APRÈS 44 véhicules détectés

Même scène du jeu de test, avant et après fine-tuning (image val_000556).

Aïchatou Traoré · Benoît Djossou · Andréa Afouda
Projet Intégrateur 1 · Groupe 5

Résumé

La République du Bénin a engagé la mise en place d'un système national de vidéoprotection dont la vidéo-verbalisation par vision par ordinateur est une application clef. Le premier maillon du pipeline, la détection des véhicules, échoue le plus souvent sur les véhicules éloignés, de petite taille à l'image ou masqués dans les embouteillages, qui sont précisément les configurations dominantes du trafic urbain ouest-africain. Nous étudions si un fine-tuning de YOLOv8n sur du trafic urbain dense améliore cette détection. Faute de jeu de données béninois public, nous utilisons un sous-ensemble reproductible de 3 000 images (25 688 véhicules annotés) de BMD-45, jeu de caméras CCTV de Bengaluru structurellement comparable (caméras fixes, forte densité, 56 % de deux-roues), remappé vers quatre classes alignées sur COCO. Le protocole de comparaison garantit l'équité entre modèle pré-entraîné et modèle fine-tuné : mêmes images et boîtes de test, réindexation des classes, rappel ventilé par taille d'objet selon la convention COCO avec aires normalisées à la résolution d'entrée du réseau. Après 50 epochs, la mAP@0,5 passe de 0,438 à 0,825 (+88,4 %) et le rappel des objets de moins de 32×32 pixels de 0,122 à 0,694 (+469,4 %), le gain étant d'autant plus fort que les objets sont petits. L'adaptation de domaine par fine-tuning lève donc précisément le verrou visé et quantifie le bénéfice qu'apporterait un jeu de données local.

Mots-clés : détection d'objets ; YOLOv8 ; fine-tuning ; petits objets ; trafic urbain dense ; vidéoprotection.

1 Introduction

Contexte. La République du Bénin a engagé la mise en place d'un système national de vidéoprotection couvrant cinq villes et les postes frontaliers, décidée en Conseils des Ministres du 11 mars et du 3 juin 2026 [7]. Au-delà de la sécurité publique, un tel réseau de caméras ouvre la voie à la vidéo-verbalisation : un pipeline de vision par ordinateur qui enchaîne détection des véhicules, suivi multi-objets, détection de plaque d'immatriculation, reconnaissance optique de caractères, application de règles d'infraction et restitution sur tableau de bord (figure 1).

Problème. Tout ce pipeline repose sur son premier maillon : si un véhicule n'est pas détecté, rien en aval ne peut le rattraper. Or les détecteurs génériques, pré-entraînés sur des jeux comme COCO [3], échouent précisément dans les configurations les plus fréquentes du trafic urbain ouest-africain : véhicules éloignés de la caméra donc de petite taille à l'image, et véhicules partiellement masqués dans les embouteillages. Les auteurs de BMD-45 [8] quantifient cet écart de domaine : des détecteurs entraînés sur le benchmark UA-DETRAC [9] plafonnent à 33,6 % de mAP@0,5 : 0,95 sur du trafic urbain dense de pays en développement, contre 83,8 % pour des modèles entraînés en domaine, soit un facteur 2,5.

Périmètre et question de recherche. Ce travail se restreint volontairement au premier maillon, la détection de véhicules, et à l'intérieur de celui-ci à un verrou précis : les véhicules éloignés, de petite taille ou masqués. Le suivi multi-objets, la lecture de plaques, les règles d'infraction et l'estimation de vitesse sont hors périmètre. La question de recherche est la suivante : *un fine-tuning de YOLOv8 sur du trafic urbain dense améliore-t-il la détection des véhicules, et spécifiquement celle des véhicules de petite taille ?* Aucun jeu de données public de vision par ordinateur n'existant pour le Bénin, l'étude s'appuie sur BMD-45, un jeu de trafic urbain indien structurellement comparable (caméras CCTV fixes, forte densité, dominance des deux-roues), sans prétendre pour autant à une adaptation au trafic béninois lui-même (section 5).




FIGURE 1 – La chaîne de vidéo-verbalisation, du flux caméra au tableau de bord. Ce travail porte sur le premier maillon : un véhicule non détecté est perdu pour toute la suite de la chaîne.

Contributions. Nos contributions sont au nombre de trois :

1. un protocole de comparaison équitable entre un modèle pré-entraîné (80 classes COCO) et un modèle fine-tuné (4 classes), fondé sur le remappage des annotations vers un espace de classes aligné sur COCO et leur réindexation à la volée, de sorte que les deux modèles sont évalués sur exactement les mêmes images et les mêmes boîtes de référence (section 3.3);
2. le fine-tuning reproductible d'un YOLOv8n sur un sous-ensemble de 3 000 images de BMD-45 extrait avec graines fixées, avec des augmentations choisies pour la problématique des petits objets (section 3.2);
3. une évaluation ventilée par taille d'objet selon la convention COCO, avec normalisation des aires à la résolution d'entrée du réseau, qui montre que le gain de rappel est d'autant plus fort que les objets sont petits : de 0,122 à 0,694 (+469,4 %) pour les objets de moins de 32×32 pixels (section 4).

La suite de l'article est organisée ainsi : la section 2 situe le travail, la section 3 détaille données, entraînement et protocole d'évaluation, la section 4 rapporte les résultats, la section 5 les interprète et énonce les limites, et la section 6 conclut.

2 Travaux connexes

Détection d'objets en une passe. La famille YOLO [5] a imposé le paradigme de la détection en une seule passe : l'image entière traverse une fois le réseau, qui prédit conjointement positions et classes, ce qui permet l'inférence temps réel indispensable à la vidéoprotection. Les versions successives ont notamment enrichi les augmentations de données : l'augmentation *mosaic*, introduite avec YOLOv4 [1], assemble quatre images en une et expose le réseau à des objets réduits et à des contextes variés. YOLOv8 [2] en est l'implémentation de référence actuelle chez Ultralytics ; sa déclinaison nano, la plus légère, est celle utilisée ici.

Le cas des petits objets. La difficulté des détecteurs sur les petits objets est documentée depuis la création du benchmark COCO [3], au point que son protocole officiel ventile les métriques en trois catégories de taille (petit, moyen, grand), convention que nous reprenons (section 3.3). La cause est structurelle : après les sous-échantillonnages successifs du réseau, un véhicule de moins de 32×32 pixels ne pèse plus que quelques activations, souvent insuffisantes pour déclencher une détection. C'est précisément la configuration des véhicules éloignés ou masqués dans les embouteillages qui nous occupe.

Jeux de données de trafic et écart de domaine. Les benchmarks historiques de surveillance de trafic, comme UA-DETRAC [9] (100 séquences filmées en Chine), proviennent de contextes routiers peu représentatifs des métropoles denses des pays en développement. BMD-45 [8] comble ce manque avec 45 000 images issues de plus de 3 600 caméras CCTV opérationnelles à Bengaluru, annotées en 14 catégories fines incluant des modes de transport régionaux. Ses auteurs quantifient l'écart de domaine : des détecteurs entraînés sur UA-DETRAC atteignent 33,6 % de mAP@0,5 :0,95 sur leur jeu, contre 83,8 % pour des modèles entraînés en domaine, un facteur 2,5 qui justifie à lui seul la démarche d'adaptation entreprise ici.

Vision par ordinateur pour le trafic en Afrique. Les travaux africains sur le sujet restent rares. Mugizi *et al.* [4] ont développé en Ouganda un système complet de surveillance du trafic (détection de véhicules, lecture de plaques et estimation de vitesse) atteignant 97,9 % de mAP en détection de plaques. Leur travail couvre le pipeline de bout en bout ; le nôtre est complémentaire : nous isolons le premier maillon, la détection, et son point de fragilité documenté, les petits objets. À notre connaissance, il n'existe aucun jeu de données public de vision par ordinateur consacré au trafic béninois, ce qui motive le choix d'un domaine structurellement comparable (section 3.1) et constitue la première limite discutée en section 5.

TABLE 1 – Remappage des 14 classes BMD-45 vers les 4 classes alignées sur COCO. L’identifiant COCO est celui utilisé lors de la réindexation du protocole d’évaluation (section 3.3).

Classes BMD-45	Classe retenue	Identifiant COCO
Hatchback, Sedan, SUV, MUV, Van	voiture	2 (<i>car</i>)
Two-wheeler	moto	3 (<i>motorcycle</i>)
Bus, Mini-bus, Tempo-traveller	bus	5 (<i>bus</i>)
Truck, LCV	camion	7 (<i>truck</i>)
Three-wheeler, Bicycle, Other	ignorées (aucun équivalent COCO)	

TABLE 2 – Effectifs du sous-ensemble par split et par classe après remappage vers les 4 classes alignées sur COCO.

Split	Images	voiture	moto	bus	camion	Total instances
train	2 400	5 744	11 641	1 298	1 873	20 556
val	300	752	1 476	138	215	2 581
test	300	742	1 380	189	240	2 551
Total	3 000	7 238	14 497	1 625	2 328	25 688

3 Méthodologie

3.1 Jeu de données

Source. Nous utilisons BMD-45 [8], un jeu de données publié à CVPR 2026 (Findings) et diffusé sous licence CC BY 4.0. Il comprend 45 000 images et 480 000 boîtes englobantes annotées, issues de plus de 3 600 caméras CCTV opérationnelles du réseau de vidéosurveillance de Bengaluru (Inde), avec 14 catégories fines de véhicules. Ce jeu présente trois caractéristiques qui motivent son choix : des caméras fixes de vidéoprotection (et non des caméras embarquées), un trafic urbain dense, et une forte proportion de deux-roues, trois traits structurels partagés avec le trafic urbain béninois (cf. section 5 pour les limites de ce rapprochement).

Extraction du sous-ensemble. Pour tenir dans le budget de calcul disponible, un sous-ensemble est extrait en streaming depuis Hugging Face avec des graines fixées : 2 400 images d’entraînement (graine 42) et 600 images de validation (graine 43). BMD-45 ne fournissant pas de jeu de test, celui-ci est dérivé de la validation par une partition déterministe moitié-moitié (graine 42), soit au final 2 400 images d’entraînement, 300 de validation et 300 de test. Le jeu de test n’intervient à aucun moment dans l’entraînement ni dans la sélection du modèle.

Remappage des classes. Le modèle de référence étant pré-entraîné sur COCO [3], la comparaison n’est équitable que si les deux modèles partagent le même espace sémantique. Les 14 classes de BMD-45 sont donc ramenées aux 4 classes de véhicules communes avec COCO selon le [tableau 1](#). Les trois catégories sans équivalent COCO (*Three-wheeler*, *Bicycle*, *Other*) sont ignorées : les conserver reviendrait à demander au modèle pré-entraîné de détecter des classes qu’il ne connaît pas, ce qui fausserait la comparaison en sa défaveur.

Volumétrie. Le [tableau 2](#) donne les effectifs par split et par classe après remappage. Deux faits saillants : le sous-ensemble compte en moyenne 8,5 véhicules annotés par image, signature d’un trafic dense propice aux occlusions ; et les motos représentent 56 % des 25 688 instances, une distribution qui rapproche structurellement ce jeu du trafic béninois, dominé par les taxis-motos (zémidjans).

TABLE 3 – Hyperparamètres d’augmentation de données. Les valeurs non listées sont celles par défaut d’Ultralytics 8.4.114.

Paramètre	Valeur	Justification
<i>mosaic</i>	1,0	produit des objets plus petits (problématique)
<i>scale</i>	0,7	zoom aléatoire, mêmes effets
<i>fliplr</i>	0,5	symétrie gauche-droite plausible
<i>translate</i>	0,1	translations légères
<i>hsv_h</i>	0,015	variations de teinte
<i>hsv_s</i>	0,7	variations de saturation
<i>hsv_v</i>	0,4	variations de luminosité (heures, météo)
<i>flipud</i>	0,0	désactivé : une scène routière a un haut et un bas
<i>degrees</i>	0,0	désactivé : caméras fixes

3.2 Modèle et entraînement

Modèle. Nous partons de YOLOv8n [2], la déclinaison la plus compacte (3,2 millions de paramètres) de la famille YOLOv8, héritière de l’architecture à une passe introduite par YOLO [5]. Le choix du modèle *nano* est un compromis assumé entre coût d’entraînement et représentativité : c’est aussi la taille la plus plausible pour une inférence temps réel sur du matériel modeste. Le fine-tuning démarre des poids pré-entraînés sur COCO [3], qui servent également de modèle de référence dans la comparaison.

Hyperparamètres. L’entraînement utilise Ultralytics 8.4.114 et PyTorch 2.13, sur un GPU NVIDIA T4 (Google Colab) : 50 epochs, images redimensionnées à 640 pixels, batch de 16, arrêt anticipé avec patience de 15 epochs, graine aléatoire 42. Le [tableau 3](#) récapitule les augmentations de données. Deux d’entre elles sont directement rattachées à la problématique : *mosaic* (assemblage de quatre images en une) et *scale* (zoom aléatoire $\pm 70\%$) produisent mécaniquement des objets plus petits que ceux du jeu d’origine, ce qui expose le modèle à la configuration visée, celle des véhicules éloignés et de petite taille. À l’inverse, le retournement vertical et la rotation sont désactivés (*flipud* = 0, *degrees* = 0) : les caméras de vidéoprotection sont fixes et une scène routière possède un haut et un bas ; ces transformations créeraient des configurations jamais rencontrées en exploitation.

3.3 Protocole d’évaluation

Les deux modèles (YOLOv8n pré-entraîné sur COCO et YOLOv8n fine-tuné) sont évalués sur exactement les mêmes 300 images de test et les mêmes 2 551 boîtes de référence. Trois précautions garantissent l’équité et la pertinence de la comparaison.

1. Alignement et réindexation des classes. Le modèle pré-entraîné expose les 80 classes COCO, le modèle fine-tuné en expose 4. Les labels du jeu de test sont donc réindexés à la volée vers l’espace de classes du modèle évalué : pour le modèle COCO, $0 \rightarrow 2, 1 \rightarrow 3, 2 \rightarrow 5, 3 \rightarrow 7$; pour le modèle fine-tuné, les indices 0 à 3 sont conservés. Le modèle COCO est de plus restreint aux classes $\{2, 3, 5, 7\}$ lors de l’inférence, afin qu’il ne soit pas pénalisé par des détections hors périmètre (piétons, feux de signalisation, etc.) qui seraient comptées comme faux positifs.

2. Rappel ventilé par taille d’objet. La problématique portant sur les véhicules petits et éloignés, le rappel est ventilé selon la convention COCO : *petit* si l’aire de la boîte est inférieure à 32×32 pixels, *moyen* si elle est inférieure à 96×96 pixels, *grand* au-delà. Point crucial : les aires sont ramenées à la résolution d’entrée du réseau (640 pixels) avant classement. Sans cette normalisation, sur des images de plusieurs milliers de pixels de large, la quasi-totalité des véhicules tombe dans la catégorie « grand » et la ventilation ne mesure plus rien. C’est précisément ce qui s’est produit lors de notre premier essai, et ce qui

a conduit à cette correction du protocole. Le calcul procède par appariement glouton : les prédictions (seuil de confiance 0,25) sont appariées aux boîtes de référence par IoU décroissant (équation (3)), avec un seuil $\text{IoU} \geq 0,5$; une prédiction ne peut valider qu'une seule boîte de référence ; la mesure est agnostique à la classe.

3. Jeu de test isolé. Le jeu de test, dérivé de façon déterministe (section 3.1), n'a jamais été vu à l'entraînement ni utilisé pour la sélection du modèle ou des hyperparamètres.

Métriques. Nous rapportons la précision, le rappel et le F1-score (équations (1) et (2)), la mAP à IoU fixé à 0,5 et moyennée de 0,5 à 0,95 (équation (4)), le débit d'inférence en images par seconde (FPS, mesuré sur GPU T4, une inférence d'échauffement exclue de la mesure), et le rappel ventilé petit / moyen / grand décrit ci-dessus. Les métriques globales sont calculées par le validateur d'Ultralytics avec un seuil de confiance de 0,001 et un seuil IoU de 0,6 : le seuil de confiance très bas est nécessaire pour tracer la courbe précision-rappel complète dont la mAP est l'aire sous la courbe.

$$\text{Précision} = \frac{VP}{VP + FP}, \quad \text{Rappel} = \frac{VP}{VP + FN}, \quad (1)$$

où VP , FP et FN désignent respectivement les vrais positifs, faux positifs et faux négatifs ;

$$F_1 = 2 \cdot \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}, \quad (2)$$

$$\text{IoU}(A, B) = \frac{|A \cap B|}{|A \cup B|} \quad (3)$$

pour deux boîtes A et B ; et

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N \text{AP}_i, \quad (4)$$

où AP_i est l'aire sous la courbe précision-rappel de la classe i et N le nombre de classes.

4 Résultats

4.1 Métriques globales et rappel par taille

Le [tableau 4](#) compare les deux modèles sur le jeu de test (300 images, 2 551 boîtes de référence). Toutes les métriques globales progressent : la $\text{mAP}@0,5$ passe de 0,438 à 0,825 (+88,4 %), la $\text{mAP}@0,5 : 0,95$ de 0,296 à 0,644 (+117,8 %), la précision de 0,496 à 0,833 (+67,9 %), le rappel de 0,417 à 0,714 (+71,1 %) et le F1-score de 0,453 à 0,769 (+69,6 %). Le débit d'inférence sur GPU T4 passe de 37,2 à 43,2 images par seconde (+16,2 %).

La [figure 2](#) visualise la ligne décisive du tableau : le rappel par taille d'objet. L'écart entre les deux modèles y est d'autant plus visible que les objets sont petits, ce qui répond directement à la question de recherche.

En effectifs, sur les 804 objets petits du jeu de test, le modèle pré-entraîné en détecte 98 (rappel de 0,122) et le modèle fine-tuné 558 (rappel de 0,694), soit un écart relatif de +469,4 %. Sur les 1 415 objets moyens, les détections passent de 528 à 1 244 (0,373 à 0,879, +135,6 %) ; sur les 332 objets grands, de 263 à 316 (0,792 à 0,952, +20,2 %). L'écart relatif est ainsi d'autant plus grand que les objets sont petits : +469,4 %, +135,6 % et +20,2 % pour les trois catégories de taille. On note que les trois catégories totalisent $804 + 1\,415 + 332 = 2\,551$ objets, soit exactement le nombre d'instances du jeu de test ([tableau 2](#)).

TABLE 4 – Comparaison sur le jeu de test entre YOLOv8n pré-entraîné (COCO) et fine-tuné sur le sous-ensemble BMD-45. Le rappel par taille suit la convention COCO (petit $< 32 \times 32$ px, moyen $< 96 \times 96$ px, grand au-delà), aires ramenées à la résolution d'entrée du réseau (640 px); seuil de confiance 0,25, IoU $\geq 0,5$. La ligne en gras répond directement à la problématique des véhicules éloignés et de petite taille.

Métrique	Pré-entraîné	Fine-tuné	Écart
mAP@0,5	0,438	0,825	+88,4 %
mAP@0,5 :0,95	0,296	0,644	+117,8 %
Précision	0,496	0,833	+67,9 %
Rappel	0,417	0,714	+71,1 %
F1-score	0,453	0,769	+69,6 %
Débit (FPS, GPU T4)	37,2	43,2	+16,2 %
Rappel objets petits (804 objets)	0,122	0,694	+469,4 %
Rappel objets moyens (1 415 objets)	0,373	0,879	+135,6 %
Rappel objets grands (332 objets)	0,792	0,952	+20,2 %




FIGURE 2 – Rappel par taille apparente d'objet avant et après fine-tuning (jeu de test, seuil de confiance 0,25, IoU $\geq 0,5$). Le gain est d'autant plus fort que les objets sont petits : c'est la réponse visuelle à la question de recherche.

4.2 Résultats par classe

Le [tableau 5](#) ventile la précision moyenne (AP) par classe, calculée par le validateur d'Ultralytics selon le protocole du [section 3.3](#) (vue réindexée en COCO pour le modèle pré-entraîné). Les quatre classes progressent, mais l'essentiel se lit sur la ligne des motos : classe la plus faible du modèle pré-entraîné (AP@0,5 de 0,263, et 0,083 seulement en AP@0,5 :0,95), elle devient la deuxième meilleure du modèle fine-tuné (0,863). Ce résultat rejoint la ventilation par taille : les motos représentent 74,6 % des objets petits du jeu de test (600 sur 804), et constituent précisément la catégorie que le trafic dominé par les deux-roues rend critique. Le camion, classe la moins dotée en exemples, progresse lui aussi nettement (0,269 à 0,744 en AP@0,5).

4.3 Illustrations qualitatives et courbes d'entraînement

La [figure 3](#) montre les détections des deux modèles sur une même scène d'embouteillage du jeu de test. La [figure 4](#) présente l'évolution des fonctions de perte et de la mAP sur le jeu de validation au fil des 50 epochs d'entraînement.

TABLE 5 – Précision moyenne par classe sur le jeu de test, avant et après fine-tuning (validateur Ultralytics, seuil de confiance 0,001, protocole du [section 3.3](#)). La classe moto, dominante dans le trafic étudié et dans les objets petits, est celle où l'écart est le plus grand.

Classe	Instances	AP@0,5		AP@0,5 :0,95	
		Pré-entraîné	Fine-tuné	Pré-entraîné	Fine-tuné
voiture	742	0,713	0,907	0,517	0,759
moto	1 380	0,263	0,863	0,083	0,614
bus	189	0,505	0,786	0,394	0,639
camion	240	0,269	0,744	0,188	0,566

4.4 Analyse des erreurs résiduelles

Le modèle fine-tuné manque encore 246 des 804 objets petits. Pour caractériser ces erreurs, nous avons rejoué l'appariement du rappel par taille (seuil de confiance 0,25, $\text{IoU} \geq 0,5$, appariement agnostique à la classe) en comparant les petits objets manqués aux petits objets détectés. Trois constats.

D'abord, la taille reste le facteur dominant : le côté apparent médian des objets manqués est de 19 pixels, contre 24 pour les objets détectés. Même sous le seuil des 32×32 pixels, la probabilité de détection continue donc de décroître avec la taille. Ensuite, l'occlusion double le risque d'erreur : 17,9 % des objets manqués recouvrent une autre boîte réelle avec un IoU supérieur à 0,2, contre 7,3 % des objets détectés. Enfin, deux facteurs sont hors de cause : la classe (les motos représentent 71,5 % des manqués contre 76,0 % des détectés, proportions comparables) et la position au bord de l'image (11,0 % contre 9,1 %).

Les erreurs résiduelles se concentrent donc sur les objets aux limites de l'information disponible, très petits ou masqués, et non sur un biais de classe que davantage de données du même type corrigerait. Ce diagnostic oriente les prolongements ([section 6](#)) vers une résolution d'entrée supérieure ou une architecture à meilleure fusion multi-échelle, plutôt que vers un simple accroissement du volume d'entraînement.

4.5 Dynamique d'entraînement

Les courbes de la [figure 4](#) apportent trois informations que les métriques finales seules ne donnent pas.


Une convergence rapide puis un plateau. La mAP@0,5 :0,95 sur le jeu de validation passe de 0,406 après la première epoch à 0,669 à la cinquantième, avec un maximum de 0,670 atteint à l'epoch 47. Elle franchit dès l'epoch 29 le seuil de 95 % de sa valeur finale : les vingt et une dernières epochs n'apportent que les 5 % restants. Le décrochage visible à l'epoch 2, où la mAP@0,5 recule de 0,591 à 0,534, correspond à la montée en puissance du taux d'apprentissage pendant la phase d'échauffement, et se résorbe dès l'epoch 4. L'essentiel de l'adaptation au domaine se joue donc dans le premier tiers de l'entraînement, ce qui est cohérent avec l'idée que le fine-tuning réutilise des représentations déjà formées plutôt qu'il n'en apprend de nouvelles.

Aucun surapprentissage à 50 epochs. Les trois pertes d'entraînement décroissent de façon monotone ($1,347 \rightarrow 0,814$ pour la boîte, $2,089 \rightarrow 0,611$ pour la classification, $1,107 \rightarrow 0,932$ pour la DFL). Surtout, les pertes de validation atteignent leur minimum en toute fin d'entraînement : epoch 50 pour la perte de boîte, 49 pour la classification, 46 pour la DFL. L'écart entre pertes d'entraînement et de validation ne se creuse à aucun moment, et l'arrêt anticipé (*patience* de 15 epochs, [section 3.2](#)) n'a jamais été déclenché. Le modèle n'avait donc pas commencé à surapprendre lorsque l'entraînement s'est arrêté.

Le budget de calcul, et non la convergence, a fixé l'arrêt. Les deux observations précédentes se combinent en une conclusion méthodologique : les 50 epochs constituent une borne que nous avons imposée, pas un point d'arrêt que les données auraient dicté. Les métriques rapportées au [tableau 4](#) sont donc à lire comme un plancher, et non comme le plafond de ce que cette architecture peut atteindre sur ce



(a) YOLOv8n pré-entraîné (COCO) : 4 véhicules détectés.



(b) YOLOv8n fine-tuné : 44 véhicules détectés.



(c) File lointaine (encadré rouge), pré-entraîné : une seule détection.



(d) La même file, fine-tuné : la quasi-totalité des véhicules est encadrée.

FIGURE 3 – Détections des deux modèles sur une même scène d’embouteillage du jeu de test (image val_000556, seuil de confiance 0,25). L’encadré rouge délimite la file de véhicules éloignés agrandie sur la rangée du bas : c’est précisément sur ces objets de petite taille à l’image que se joue l’écart entre les deux modèles. Les visages sont floutés à la source dans BMD-45 ; la seule plaque d’immatriculation partiellement lisible a été floutée par nos soins.

jeu. L’entraînement complet a demandé 54,9 minutes sur GPU T4, ce qui laisse une marge confortable pour prolonger l’expérience dans le cadre gratuit de Google Colab.

5 Discussion

5.1 Le verrou visé est bien celui qui est levé

La lecture centrale du [tableau 4](#) est le gradient des gains selon la taille des objets : +469,4 % de rappel pour les objets petits, +135,6 % pour les moyens, +20,2 % pour les grands. L’amélioration est d’autant plus forte que l’objet est petit, c’est-à-dire exactement là où le modèle générique échouait : le modèle pré-entraîné ne retrouvait qu’un objet petit sur huit (0,122), le modèle fine-tuné en retrouve plus des deux tiers (0,694). La réponse à la question de recherche est donc positive, et elle l’est de manière ciblée : le fine-tuning sur du trafic urbain dense n’améliore pas seulement les métriques globales, il lève spécifiquement le verrou des véhicules éloignés, de petite taille ou masqués qui motivait ce travail. Les augmentations orientées petits objets (*mosaic*, *scale*, [section 3.2](#)) et la densité du jeu d’entraînement (8,5 véhicules par image en moyenne) sont les explications les plus plausibles de ce ciblage, sans que notre protocole permette d’isoler la contribution de chacune ; une étude d’ablation serait nécessaire.

5.2 Cohérence avec l’écart de domaine rapporté par BMD-45

Notre passage de 0,296 à 0,644 de $mAP@0,5 : 0,95$, soit un facteur 2,2, est cohérent avec l’écart de domaine rapporté par les auteurs de BMD-45 [8] : des détecteurs entraînés sur UA-DETRAC [9] atteignent 33,6 % de $mAP@0,5 : 0,95$ sur leur jeu, contre 83,8 % pour des modèles entraînés en domaine, soit un facteur 2,5. Nous retrouvons cet ordre de grandeur avec un modèle nano et 6,7 % des images du jeu




FIGURE 4 – Courbes d’entraînement du fine-tuning : fonctions de perte (boîte, classification, DFL) et mAP@0,5 et mAP@0,5 :0,95 sur le jeu de validation, au fil des 50 epochs. Les pertes d’entraînement sont en trait plein, celles de validation en pointillés. La ligne verticale marque l’epoch 47, où la mAP@0,5 :0,95 de validation atteint son maximum.

complet : l’essentiel de l’écart entre un détecteur générique et un détecteur adapté semble donc se combler dès un fine-tuning modeste, ce qui est une information directement utile pour un déploiement à budget contraint.

5.3 Ce que le fine-tuning ne résout pas

Le rappel des objets petits plafonne à 0,694 : 246 des 804 objets petits du jeu de test restent non détectés. Une partie de ce résidu relève d’une limite informationnelle et non d’un défaut de l’approche : sous un certain nombre de pixels, l’information nécessaire à la détection n’existe simplement plus dans l’image, et aucun modèle, quelle que soit sa taille, ne peut la reconstituer. Ce plafond suggère que les marges de progression restantes sont à chercher du côté de la résolution d’entrée, de l’inférence par tuiles ou du placement des caméras, plutôt que du seul entraînement.

Le gain de débit (+16,2 %, de 37,2 à 43,2 FPS) doit être interprété avec prudence : l’architecture étant identique, il ne peut provenir du réseau lui-même. L’hypothèse la plus plausible est un post-traitement (suppression des non-maxima) allégé par la réduction de 80 à 4 classes, à quoi s’ajoute la variabilité de mesure inhérente à un environnement partagé comme Google Colab. Nous n’avons pas conçu d’expérience pour départager ces deux effets.

5.4 Limites

Domaine indien, contexte béninois. Il n’existe à ce jour aucun jeu de données public de vision par ordinateur spécifique au Bénin. Nous avons donc travaillé sur du trafic dense indien, structurellement comparable au trafic béninois sur trois points : caméras CCTV fixes, forte densité, dominance des deux-roues (56 % des instances, à rapprocher des zémidjans). Nos résultats établissent que l’adaptation à un domaine de trafic dense de ce type est possible et fortement bénéfique ; ils ne démontrent pas que le modèle obtenu est adapté au trafic béninois lui-même. La constitution d’un jeu de données local reste le préalable à toute conclusion de ce type.

Échelle des expériences. Le sous-ensemble utilisé représente 3 000 images sur les 45 000 disponibles, le modèle est la déclinaison nano, et l’entraînement est limité à 50 epochs : ces choix, imposés par le temps machine disponible, bornent la portée des chiffres absolus rapportés, même si la comparaison relative entre les deux modèles reste valide puisqu’ils sont évalués dans des conditions identiques. La [section 4.5](#) permet de préciser cette limite plutôt que de seulement la constater : les pertes de validation étant encore à leur minimum à la dernière epoch, la borne des 50 epochs a effectivement été atteinte avant la convergence.

Nos chiffres absolus sont donc un plancher, et prolonger l’entraînement est la première expérience à mener — avant même de passer à une déclinaison de modèle plus grande ou au jeu de données complet.

Classes minoritaires. Les bus (189 instances) et camions (240 instances) sont minoritaires dans le jeu de test : les métriques qui les concernent sont mécaniquement moins stables que celles des voitures (742) et motos (1 380), et nous ne rapportons pas de métriques par classe pour cette raison.

Contamination potentielle entre splits. Nos splits sont dérivés de façon déterministe, mais BMD-45 étant constitué d’images de caméras fixes, des images quasi identiques (même caméra, instants proches) peuvent se retrouver de part et d’autre de la séparation train/test, un risque de contamination connu dans les jeux publics qui tendrait à flatter les métriques absolues des deux modèles sans invalider leur comparaison.

Protection des données personnelles. Les plaques d’immatriculation et les visages sont des données à caractère personnel. Tout déploiement réel d’un système de vidéoprotection au Bénin suppose un cadre juridique conforme au code du numérique [6] et le contrôle de l’Autorité de protection des données personnelles (APDP). Le présent travail, mené sur un jeu de données public diffusé sous licence CC BY 4.0, n’implique aucune collecte de données.

6 Conclusion

Nous avons montré qu’un fine-tuning modeste (3 000 images, modèle nano, 50 epochs sur un GPU T4) suffit à transformer un détecteur générique en un détecteur adapté au trafic urbain dense, et que le gain se concentre là où il était attendu : le rappel des véhicules de moins de 32×32 pixels passe de 0,122 à 0,694 (+469,4 %), tandis que la mAP@0,5 progresse de 0,438 à 0,825 (+88,4 %), à débit d’inférence au moins égal. La valeur du travail tient autant au protocole qu’aux chiffres : classes alignées sur COCO et réindexées pour une comparaison équitable, rappel ventilé par taille avec aires normalisées à la résolution d’entrée, jeu de test isolé et dérivé de façon déterministe. Une démonstration interactive, qui rejoue cette comparaison sur toute image ou vidéo téléversée, est déployée en ligne¹ ; le code, les poids fine-tunés et le protocole d’évaluation sont versionnés dans le dépôt du projet.

Trois prolongements se dégagent, par ordre de priorité. D’abord, la constitution d’un jeu de données annoté de trafic béninois, préalable indispensable pour transformer un résultat obtenu sur un domaine comparable en un résultat établi sur le domaine cible, et dont ce travail fournit le protocole d’évaluation clef en main. Ensuite, le passage à l’échelle : entraîner sur les 45 000 images de BMD-45 et sur des déclinaisons plus grandes de YOLOv8 (s, m), pour mesurer ce que le plafond observé sur les petits objets doit au modèle et ce qu’il doit à la limite informationnelle. Enfin, la poursuite du pipeline de vidéo-verbalisation (suivi multi-objets puis lecture de plaques), dont la détection fiabilisée par ce travail constitue le socle.



Démonstration en ligne

Références

- [1] Alexey Bochkovskiy, Chien-Yao Wang, and Hong-Yuan Mark Liao. YOLOv4 : Optimal speed and accuracy of object detection, 2020. arXiv :2004.10934.
- [2] Glenn Jocher, Ayush Chaurasia, and Jing Qiu. Ultralytics YOLOv8, 2023. Version 8.4.114.

1. <https://detection-vehicules-benin.streamlit.app>

- [3] Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. Microsoft COCO : Common objects in context. In *European Conference on Computer Vision (ECCV)*, pages 740–755, 2014.
- [4] Bruce Mugizi, Sudi Murindanyi, Olivia Nakacwa, and Andrew Katumba. Intelligent traffic surveillance for real-time vehicle detection, license plate recognition, and speed estimation, 2026. arXiv :2601.00344.
- [5] Joseph Redmon, Santosh Divvala, Ross Girshick, and Ali Farhadi. You only look once : Unified, real-time object detection. In *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 779–788, 2016.
- [6] République du Bénin. Loi n° 2017-20 du 20 avril 2018 portant code du numérique en république du bénin, 2018.
- [7] Secrétariat Général du Gouvernement du Bénin. Comptes rendus des conseils des ministres du 11 mars 2026 et du 3 juin 2026. <https://sgg.gouv.bj>, 2026.
- [8] Akash Sharma, Chinmay Mhatre, Sankalp Gawali, Ruthvik Bokkasam, Brij Kishore, Vishwajeet Pattanaik, Tarun Rambha, Abdul R. Pinjari, Vijay Kovvali, Anirban Chakraborty, Punit Rathore, Raghu Krishnapuram, and Yogesh Simmhan. BMD-45 : A large-scale CCTV vehicle detection dataset for urban traffic in developing cities. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Findings Track*, 2026. arXiv :2604.24419. Jeu de données : <https://huggingface.co/datasets/iisc-aim/BMD-45>, licence CC BY 4.0.
- [9] Longyin Wen, Dawei Du, Zhaowei Cai, Zhen Lei, Ming-Ching Chang, Honggang Qi, Jongwoo Lim, Ming-Hsuan Yang, and Siwei Lyu. UA-DETRAC : A new benchmark and protocol for multi-object detection and tracking. *Computer Vision and Image Understanding*, 193 :102907, 2020.